

ACE-SKILL

ACE-SKILL: Bootstrapping Multimodal Agents with Prioritized and Clustered Evolution

论文: (<https://arxiv.org/abs/2605.08887>)

作者: Feng Xiong、Zengbin Wang、Yong Wang、Xuecai Hu、Jinghan He、Liang Lin、Yuan Liu、Xiangxiang Chu

机构: AMAP, Alibaba Group、CASIA、Beijing Normal University

代码: [AMAP-ML/Ace-Skill](#)

数据: [TIR-Bench](#)、[VisualToolBench](#)、[MMSearch-Plus](#)、[AgentVista](#)

(需提前阅读Xskill论文)




Figure 2: Overview of the ACE-SKILL framework. ACE-SKILL breaks the vicious cycle between data inefficiency and knowledge interference through a prioritized sampler and a clustered organizer.

一、motivation

1.智能体积累经验时计算资源分配方案不够最优

例如: Xskill积累skill时, 简单题目与困难题目均会生成四条运行轨迹, 实际效果中, 简单题可能只需两条轨迹, 难题需六条轨迹。大量计算被浪费在“已经学会”的任务上, 而真正包含学习价值的困难任务没有得到充分探索

2.学到的知识互相干扰

例如：

经验知识库可能同时包含：

- OCR 文字识别；
- 迷宫和网格推理；
- 网页搜索；
- 代码生成；
- GUI 操作

当智能体解决迷宫任务时，检索系统可能返回通用图像预处理建议，甚至返回“如何辨认相似字符”之类无关经验。相关知识被噪声稀释，智能体就可能选错工具或走错推理路径

二、方法

模块1：分类和初始化

(1)分类

输入： 训练集 $\mathcal{D}$ ，实际使用每条样本的问题文本 Q_i 和样本编号 `doc_id`。

处理： 使用 Embedding 模型将 Q_i 转换为语义向量，再使用 K-means 聚类。

输出： 每条训练样本对应的类别编号 `cluster_id`，以及用于新样本路由的聚类中心

执行者： Embedding 模型和程序代码

(2)掌握度参数与每个类别知识簇初始化

调用时间： 训练开始前，只执行一次

输入：

- 样本数量 (N)；
- 聚类数量 (K)；
- 样本的类别编号

处理：

为每个类别初始化知识簇：

$$C_k = (E_k, S_k)$$

$$E_k = \emptyset, \quad S_k = \emptyset$$

为每条样本初始化掌握度统计：

$$\alpha_i = 0, \quad \beta_i = 0, \quad t_i = 0$$

$$\tilde{\alpha}_i = \alpha_i \rho^{t-t_i}$$

$$\tilde{\beta}_i = \beta_i \rho^{t-t_i}$$

$$v_i = \frac{1 + \tilde{\alpha}_i}{2 + \tilde{\alpha}_i + \tilde{\beta}_i}$$

初始掌握度为：

$$v_i = 0.5$$

输出：

- K个空知识簇
 - 每条样本的初始掌握度状态
- 执行者：** 程序代码
-

模块2：优先采样器根据掌握度采样

调用时间： 每个训练步开始时

输入：

- 每条样本的 α_i 、 β_i 、 t_i ；
- 当前训练步 t ；
- 参数 (ρ 、 γ 、 ϵ)；
- batch size (B)

(1)计算延迟衰减后的掌握度

$$\begin{aligned}\tilde{\alpha}_i &= \alpha_i \rho^{t-t_i} \\ \tilde{\beta}_i &= \beta_i \rho^{t-t_i} \\ v_i &= \frac{1+\tilde{\alpha}_i}{2+\tilde{\alpha}_i+\tilde{\beta}_i}\end{aligned}$$

(2)计算采样权重

$$w_t(x_i) = \sqrt{v_i(1-v_i)} + \gamma(1-v_i) + \epsilon$$

处理三：按权重无放回采样

$$\begin{aligned}p_t(x_i) &= \frac{w_t(x_i)}{\sum_{j=1}^N w_t(x_j)} \\ \mathcal{B}_t &\sim p_{\text{sample}}(\mathcal{D}, \mathbf{V})\end{aligned}$$

输出：

- 本轮训练样本集合 $\mathcal{B}_t$ ；
 - 论文中每轮包含 (B=8) 条样本
- 执行者：** 程序代码
-

模块3：知识增强 Rollout 与轨迹蒸馏

调用时间： 优先采样器选出本轮 batch 后

输入：

- 本轮训练样本集合 $\mathcal{B}_t$ ；

- 路由规则 $c(\cdot)$;
- 当前类别的知识库:
- 每条样本的图像、问题和标准答案

①回答问题

对于每条样本，根据路由公式确定其所属知识簇，之后检索experience(向量相似度)，将检索到的experience、该类别的skill文档作为提示词和图片、问题一起输入智能体，得到：

- 完整执行轨迹;
- 最终预测答案

②计算奖励

验证器根据预测答案和标准答案(A_i)计算奖励：

$$r_{t,i} \in [0, 1]$$

③提取知识

大模型分析执行轨迹、工具调用和验证结果，从中提取experience和skill

输出：

对于每条样本，输出：

- 执行奖励($r_{t,i}$);
- 新战术经验(ΔE_i);
- 新战略技能(ΔS_i)

执行者：

- 程序负责样本路由和经验检索;
- 智能体大模型负责知识适配、任务执行和工具调用;
- 验证器负责计算奖励;
- 大模型负责轨迹反思和知识提取

模块4：状态与知识更新

调用时间: 获得奖励和新知识后

输入：

- 奖励 $r_{t,i}$;
- 新知识 ($\Delta E_i, \Delta S_i$);
- 当前样本状态;
- 当前类别的知识簇

(1)更新掌握度参数

$$\alpha_i \leftarrow \tilde{\alpha}_i + r_{t,i}$$

$$\beta_i \leftarrow \tilde{\beta}_i + (1 - r_{t,i})$$

$$t_i \leftarrow t$$

(2)更新experience和skill

experience:

向量相似度检查，超过设定的阈值判定有相似技能

- 没有相似经验：直接插入
- 存在相似经验：由大模型合并；
- 超过容量：合并最相似的经验

skill:

将新的skill和skill文档以及作者编写的合并规则输入大模型，得到新的skill文档

输出：

- 更新后的样本掌握度参数
- 更新后的知识簇

执行者：

- 程序负责状态计算、相似度检索和容量控制；
- 大模型负责经验合并以及技能文档的合并与压缩

三、实验

数据集：

TIR-Bench

VisualToolBench

MMSearch-Plus

AgentVista

工具：

- **Code Interpreter**
有状态的 Python/Jupyter 环境，用于数学计算、数据分析、代码执行和图像处理，支持 NumPy、Pandas、OpenCV 等库
- **Image Search**
图片搜索工具，支持文字搜图和反向图片搜索，用于查找相关图片或识别图片来源
- **Web Search**
网页搜索工具，根据关键词返回相关网页的标题、链接和内容摘要

- **Visit**

网页访问与内容提取工具，用于打开具体网页、读取正文，并可根据当前任务生成网页内容摘要

主实验：

Model	TIR-Bench		VisualToolBench		MMSearch-Plus		AgentVista		Mean	
	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4
<i>Proprietary Multimodal Models</i>										
o4-mini* (OpenAI, 2025a)	20.13	45.00	14.72	27.57	5.92	12.32	19.04	25.69	14.95	27.65
↪ Vanilla Tools	24.62	49.50	19.63	34.11	15.88	21.80	18.12	29.36	19.56	33.69
GPT-5-mini* (OpenAI, 2025b)	20.00	46.50	13.90	22.90	3.08	6.64	18.58	28.44	13.89	26.12
↪ Vanilla Tools	23.50	50.50	24.30	37.85	14.22	20.38	20.41	35.78	20.61	36.13
Gemini-2.5-Pro* (Comanici et al., 2025)	21.37	40.00	20.91	28.97	10.43	19.43	17.89	28.44	17.65	29.21
↪ Vanilla Tools	28.38	54.00	25.35	40.65	21.56	35.55	20.18	33.94	23.87	41.04
Qwen3.5-Plus (Qwen, Team, 2026)	29.88	47.50	17.17	28.04	6.64	10.43	11.47	18.35	16.29	26.08
↪ Vanilla Tools	40.25	62.50	29.21	49.07	27.84	46.45	16.74	31.19	28.51	47.30
<i>Open-Source Multimodal Models</i>										
GLM-4.6V (GLM, Team, 2026)	17.50	28.00	17.76	34.11	3.67	8.06	15.14	24.77	13.52	23.74
↪ Vanilla Tools	18.75	42.00	15.89	31.78	17.42	34.60	15.60	31.19	16.92	34.89
Kimi-K2.5 (Team et al., 2026)	17.37	28.00	12.85	19.63	10.78	18.48	18.12	30.28	14.78	24.10
↪ Vanilla Tools	19.38	37.00	21.03	34.11	33.53	48.34	18.35	31.19	23.07	37.66
<i>Baseline and ACE-SKILL</i>										
Qwen3.5-35B-A3B (Qwen, Team, 2026)	23.00	43.00	15.65	28.04	3.67	7.58	10.32	17.43	13.16	24.01
↪ Vanilla Tools	39.37	65.00	21.38	39.72	16.59	28.44	15.37	32.11	23.18	41.32
↪ w/ XSkill (Jiang et al., 2026b)	40.62	68.00	22.43	35.51	23.93	41.23	16.51	29.36	25.87	43.53
↪ w/ ACE-SKILL	50.00	71.50	26.40	41.59	28.55	43.13	20.64	36.70	31.40	48.23

大模型积累的经验给小模型：

Table 3: Scalability and zero-shot transfer results (Avg@4 and Pass@4). Top: scaling ACE-SKILL to Qwen3.5-122B-A10B. Bottom: directly injecting knowledge bootstrapped by 35B-A3B into smaller models (9B, 4B) without retraining. **Bold** indicates the best result.

Model	TIR-Bench		VisualToolBench		MMSearch-Plus		AgentVista		Mean	
	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4
<i>Exploring More Scalable Model (122B-A10B)</i>										
Qwen3.5-122B-A10B (Qwen, Team, 2026)	22.13	41.00	13.90	22.90	4.03	9.48	9.86	18.35	12.48	22.93
↪ Vanilla Tools	46.12	74.50	23.83	40.19	29.23	45.97	15.60	31.19	28.70	47.96
↪ w/ ACE-SKILL	53.12	75.00	29.44	50.47	33.06	49.29	18.35	33.03	33.49	51.95
<i>Transfer Evaluations of Experiences and Skills (35B-A3B → 9B, 4B)</i>										
Qwen3.5-9B (Qwen, Team, 2026)	14.75	28.50	10.16	21.03	1.66	4.27	4.59	11.93	7.79	16.43
↪ Vanilla Tools	26.75	50.50	18.11	34.11	14.45	27.49	9.17	22.94	17.12	33.76
↪ w/ ACE-SKILL	39.62	66.00	20.56	35.51	24.53	37.91	17.43	33.03	25.54	43.11
Qwen3.5-4B (Qwen, Team, 2026)	10.25	28.50	5.96	14.49	0.59	1.42	4.59	12.84	5.35	14.31
↪ Vanilla Tools	25.12	46.00	12.85	30.37	14.10	26.54	8.03	22.02	15.03	31.23
↪ w/ ACE-SKILL	33.50	61.50	15.07	29.91	19.31	29.38	11.93	22.94	19.95	35.93

不同数据集知识的迁移：

Table 4: Cross-domain generalization (OOD) performance (Avg@4). Experiences and skills are bootstrapped *only* on the source benchmark and directly transferred to a held-out target benchmark *without* any additional training or adaptation on the target domain. $\triangle$ denotes the absolute improvement over Vanilla Tools.

Model	VisualToolBench $\rightarrow$ TIR-Bench		MMSearch-Plus $\rightarrow$ AgentVista	
	Avg@4	$\triangle$	Avg@4	$\triangle$
Qwen3.5-35B-A3B (Qwen, Team, 2026)	39.37	-	15.37	-
$\hookrightarrow$ + OOD Transfer	45.50	+6.13	18.58	+3.21
Qwen3.5-122B-A10B (Qwen, Team, 2026)	46.12	-	15.60	-
$\hookrightarrow$ + OOD Transfer	50.25	+4.13	19.95	+4.35

调用次数的百分比：




Figure 3: Per-sample selection frequency of the Prioritized Evolution Sampler over 4 epochs on four benchmarks. Under uniform sampling, every sample would be visited exactly 4 times.

消融实验：

- 什么都不加
- 加工具
- 优先采样
- 加分类
- 完整




Figure 4: Ablation of proposed modules on TIR-Bench (Avg@4). **Left:** Qwen3.5-35B-A3B. **Right:** Qwen3.5-122B-A10B. Each module provides independent gains, and their combination (ACE-SKILL) yields super-additive improvement on both scales.

困难系数 γ 与时间衰减系数 ρ 的选择




Figure 5: Hyperparameter sensitivity on TIR-Bench (Avg@4). **Top:** difficulty bias γ ($\rho = 0.95$). **Bottom:** temporal decay ρ ($\gamma = 0.4$).

只有大模型
加工具
加ACE-skill

Conditions	Qwen3.5 35B-A3B	Qwen3.5 122B-A10B
Basemodel	23.00	22.13
w/ Vanilla Tools	39.37	46.12
w/ ACE-SKILL (Ours)	50.00	53.12
Ablation of Components		
w/o Base Exploration	48.88	52.00
w/o Difficulty Bias	47.50	51.25
w/o Skill Cluster	46.75	51.62
w/o Experience Cluster	48.25	53.00

去掉 ϵ
去掉 ρ
去掉skill隔离
去掉experience隔离

工作缺口：

1.分类仅根据问题文本分类，当“问题文本相似度”与“实际工具流程相似度”不一致时，ACE-Skill的固定单簇路由会在什么条件下失效？基于图像和工具计划的软多簇路由能否减少这种负迁移

请完成图片中给出的任务。

但不同图片可能分别要求：

- OCR识别；
 - 图表计算；
 - 反向图片搜索；
 - 网页信息核验；
 - GUI操作
- 2.没有解决experience和skill的存储容量较小问题
 - 3.没有判断写入的experience和skill是否可靠
 - 4.工作开始时分出的类别是固定的，在问题1的基础上如果新问题与旧有的类别十分不相似，要建立新的类别