

Web-Shepherd

论文: [Web-Shepherd: Advancing PRMs for Reinforcing Web Agents](#)

作者: Hyunjoo Chae、Sunghwan Kim、Junhee Cho、

机构: Georgia Institute of Technology、Yonsei University、Carnegie Mellon University

代码: [kyle8581/Web-Shepherd](#)

数据: [WebPRM Collection](#); [WebRewardBench](#)

Motivation (研究背景)

网页智能体需要完成长时序、多步骤的网页任务，但容易因中间步骤出错或重复错误操作而导致整个任务失败，智能体需要在执行过程中及时判断每一步是否正确

Gap (现有研究的不足)

1. 现有方法通常只在任务结束时提供成功或失败的结果奖励，无法定位具体哪一步出错，也不能提供步骤级指导
 2. 使用 GPT-4o 等多模态大模型评价候选动作，成本高、速度慢，评价结果不够可靠
 3. 网页导航领域缺少经过专门训练、能够同时用于训练和推理阶段的过程奖励模型
 4. 缺少训练网页过程奖励模型所需的步骤级偏好数据，以及专门评价这类模型的基准
-

Problem (本文要解决的问题)

如何为网页智能体构建一个低成本、可靠的过程奖励模型，使其能够在每个步骤上判断候选操作是否推动任务目标的完成，并利用该评价指导智能体选择下一步动作？

Core idea (文章的核心思想、Insight)

将任务拆成明确的中间子目标，再判断当前动作是否推动了这些子目标，从而获得更加准确、可解释且低成本的步骤级奖励

How (文章核心方法如何设计)

1. 构建WebPRM Collection

一个完整任务的数据被表示为：

$$\mathcal{D} = (I, O, C, A^+, A^-)$$

其中

- (I) ：用户指令
- $(O = (o_1, o_2, \dots, o_n))$ ：网页观察序列
- (C) ：任务的Checklist
- $(A^+ = (a_1^+, a_2^+, \dots, a_n^+))$ ：人类专家选择的动作序列，即专家轨迹
- (A^-) ：与专家动作对应的被拒绝动作

1.1 收集用户指令和专家轨迹

作者从Mind2Web使用的网站中选择能够通过Playwright访问的网站，由人类标注者：

1. 编写用户指令 (I)
 2. 实际操作网页
 3. 记录每一步观察 (O)
 4. 记录专家动作轨迹 (A^+)
- 任务被划分为简单、中等和困难三个难度等级

- 简单任务的轨迹中位数约为5步,一般包含3~4个子目标
- 中等任务约为9步,包含4~5个子目标
- 困难任务约为20步，部分超过40步

1.2 标注Checklist

根据用户指令和专家轨迹，使用GPT-4o生成子目标分析和Checklist：

$$(I, A^+) \xrightarrow{\text{GPT-4o}} C$$

Checklist采用粗粒度子目标，而不是记录每个具体点击动作

专家具体动作	Checklist中的抽象子目标
点击“MUSIC”按钮	进入音乐活动页面
点击“See All Concerts”	查看完整的音乐会列表
多次向下滚动	查找符合条件的音乐会
阅读日期、场馆和演出名称	确定下一场目标音乐会
点击筛选框并选择多个选项	完成指定条件的筛选

1.3 收集被拒绝动作

对于每个专家动作 (a_{t^+})，作者从多个策略模型中采样5个候选动作，并选出与专家动作不同的动作作为候选负样本

- Qwen-2.5-VL-7B
- Qwen-2.5-VL-72B
- GPT-4o-mini
- 使用人类轨迹微调过的Qwen-2.5-3B

2. 训练Web-Shepherd

Web-Shepherd是在WebPRM Collection上训练的过程奖励模型，支持两个功能：

1. 根据用户指令生成任务Checklist
2. 根据Checklist完成情况评价网页操作

整体信息流为：

$$I \ C(I, C, o, a) \ (,) \ (o, a)$$

其中：

- (I)：用户指令
- (C)：Checklist
- (o)：当前网页观察
- (a)：待评价的网页动作
- (F)：模型生成的文字反馈
- (J)：模型对Checklist项目的判断
- (r(o,a))：动作的过程奖励

2.1 生成Checklist

Web-Shepherd首先根据用户指令 (I) 生成Checklist：

$$C = (c_1, c_2, \dots, c_n)$$

其中每个 (c_k) 都是完成用户任务所需的自然语言子目标

这份Checklist描述完成任务的关键中间子目标，后续被用作动作评价标准
需要区分：

- 构建训练数据时，GPT-4o根据 (I) 和专家轨迹 (A^+)生成标注Checklist
- Web-Shepherd使用时，根据用户指令 (I)生成Checklist

2.2 基于Checklist生成反馈和判断

给定Checklist (C)、当前观察 (o) 和待评价动作 (a)，Web-Shepherd生成：

=
其中：

- (F)：解释动作与任务进展关系的文字反馈
- (J)：对Checklist项目完成情况的判断

模型采用下一词预测目标训练：

$$TP = - \sum_{t=1}^T \log p(o_t | I, C, o, a)$$

让模型学习根据Checklist推理并生成可解释的动作评价，而不是只输出一个分数

2.3 将语言判断转换为过程奖励

模型生成的判断属于离散文本，使用verbalizer，将语言模型输出层的token概率映射为连续奖励判断标签包括：

- **Yes**：Checklist项目已经完成
- **In Progress**：Checklist项目正在被推进
- **No**：Checklist项目没有完成

奖励计算的核心权重是：

$$w = (I, C, o, a,) + (Po I, C, o, a,)$$

- “Yes”贡献完整权重
- “In Progress”贡献一半权重
- “No”不出现在加权项中

模型对Checklist项目的得分进行聚合，得到当前观察—动作对的过程奖励 $r(o,a)$

Web-Shepherd最终输出两类信息：

1. 连续奖励： (o, a)
2. 文字反馈：解释模型为什么做出这一评价

Evidence（实验、证据、消融）

1.评价奖励模型能否在每个步骤的5个候选动作中，将专家正确动作排在错误动作之前

Table 1: Evaluation results on WEBREWARDBENCH. **T**: text observation, **I**: image observation.

Model	Inputs	Checklist	Mind2Web						WebArena	
			Cross-Task		Cross-Website		Cross-Domain		Test	
			MRR	Acc. (traj)	MRR	Acc. (traj)	MRR	Acc. (traj)	MRR	Acc. (traj)
GPT-4o-mini	T	✗	47.5	0.0	47.6	13.5	45.4	0.8	34.4	5.0
	T	✓	63.9	5.0	66.1	12.8	63.3	12.4	60.0	15.0
	T + I	✗	48.2	0.0	49.3	0.0	49.5	0.8	38.7	0.0
	T + I	✓	58.8	2.5	64.4	5.1	63.0	4.1	53.8	5.0
GPT-4o	T	✗	56.9	5.0	55.8	2.6	59.8	3.3	59.2	15.0
	T	✓	67.4	7.5	70.3	5.1	70.2	11.6	69.7	15.0
	T + I	✗	52.5	5.0	52.2	0.0	52.8	1.7	49.7	5.0
	T + I	✓	62.4	5.0	68.1	15.4	65.1	6.6	59.7	10.0
Qwen-2.5-VL-72B	T	✗	55.7	5.0	51.8	0.0	54.2	1.7	54.6	5.0
	T	✓	59.4	0.0	62.4	0.0	57.9	1.7	52.3	5.0
	T + I	✗	50.1	2.5	47.6	0.0	49.8	0.8	43.1	0.0
	T + I	✓	52.9	2.5	53.5	2.6	52.0	2.5	47.3	0.0
WEB-SHEPHERD (3B)	T	✓	87.6	55.0	88.0	43.6	87.2	47.1	91.1	60.0
	T+I	✓	85.0	42.5	87.3	41.0	84.4	37.2	92.5	65.0
WEB-SHEPHERD (8B)	T	✓	88.3	57.5	87.9	51.3	91.3	61.2	97.8	85.0

测试数据：

- Mind2Web：Cross-Task、Cross-Website、Cross-Domain

- WebArena：分布外测试集

**评价指标：

- MRR：正确动作的平均排名，越高越好
- Acc. (traj)：整条轨迹中每一步都将正确动作排在第一的比例

2.Web-Shepherd给出的过程奖励，能否真正指导网页智能体选择更好的动作，从而提高最终任务成功率

Table 2: Success rates of trajectory search with GPT-4o-mini and GPT-4o as policy on WebArena-lite.

Policy	PRM	Checklist	Shopping	CMS	Reddit	GitLab	Map	Total	Δ
GPT-4o-mini	w/o Trajectory Search	N/A	21.74	22.86	19.05	34.38	19.35	23.64	–
	GPT-4o-mini	✗	13.04	14.29	9.52	25.00	16.13	15.75	–7.89
		✓	21.74	31.43	14.29	34.38	16.13	24.24	+0.60
	WEB-SHEPHERD (3B)	✓	32.61	37.14	19.05	34.38	32.26	32.12	+8.48
	WEB-SHEPHERD (8B)	✓	26.09	45.71	23.81	40.62	35.48	34.55	+10.90
GPT-4o	w/o Trajectory Search	N/A	23.91	31.43	28.57	56.25	19.35	31.52	–
	GPT-4o-mini	✓	21.74	31.43	28.57	40.62	12.90	26.67	–4.85
	WEB-SHEPHERD (3B)	✓	28.26	37.14	47.62	53.12	25.81	36.97	+5.45
	WEB-SHEPHERD (8B)	✓	30.43	42.86	47.62	46.88	35.48	39.39	+7.87

- **w/o Trajectory Search**：不使用轨迹搜索。Policy直接生成并执行动作，不使用PRM评分和重排序
- **使用Trajectory Search**：Policy生成多个候选动作，PRM分别评分，执行奖励最高的动作
- **Policy**：负责生成候选动作
- **PRM**：负责评价和选择候选动作
- **SR/Total**：最终任务成功率

- ()：相对于同一Policy不使用轨迹搜索时的成功率变化

3.验证Web-Shepherd能否泛化到训练阶段未见过的企业办公网页环境WorkArena

Table 3: Success rates of trajectory search with GPT-4o-mini as policy on WorkArena.

PRM	Checklist	Dashboard	Form	Knowledge	List-filter	List-sort	Menu	Service Catalog	Total	Δ
w/o Trajectory Search	N/A	50.00	0.00	10.00	0.00	5.00	25.00	2.22	9.39	–
GPT-4o-mini	✓	55.00	10.00	10.00	0.00	6.67	20.00	5.56	12.42	+3.03
Web-Shepherd (3B)	✓	57.50	14.00	10.00	0.00	10.00	10.00	11.11	14.85	+5.46
Web-Shepherd (8B)	✓	65.00	14.00	20.00	0.00	10.00	20.00	7.78	15.76	+6.37

实验设置

- Policy固定为GPT-4o-mini
- WorkArena包含Dashboard、Form、Knowledge、List-filter、List-sort、Menu和服务Catalog等任务
- **w/o Trajectory Search**：GPT-4o-mini直接生成并执行动作，不使用PRM选择候选动作
- 使用轨迹搜索时，由PRM根据Checklist对候选动作评分并选择最高分动作
- Total表示总体任务成功率，()表示相对不使用轨迹搜索的变化

4.训练数据规模与负样本数量的影响

Table 5: Effect of instruction proportion and the number of rejected actions on model performance.

(a) Effect of instruction proportion.					(b) Ablation on the number of rejected actions.				
Proportion of instruction	Mind2Web		WebArena		# max rejected actions	Mind2Web		WebArena	
	MRR (step)	ACC (traj)	MRR (step)	ACC (traj)		MRR (step)	ACC (traj)	MRR (step)	ACC (traj)
0.25	68.38	11.34	65.97	10.00	1	71.42	12.79	63.04	10.00
0.5	77.46	21.54	73.57	15.00	2	77.66	17.55	76.47	20.00
0.75	83.64	33.63	88.09	55.00	3	79.70	24.91	77.46	20.00
Ours (3B)	87.62	48.57	91.06	60.00	4 (Ours, 3B)	87.62	48.57	91.06	60.00

左：用户指令数量

右：被拒绝动作数量

5.在Web-Shepherd (3B) 中，移除Checklist或移除文字反馈都会造成明显性能下降；说明Checklist提供结构化评价标准，反馈支持对动作与任务进展关系的推理，二者共同使用才能获得可靠的过程奖励




Figure 6: Results of ablation study with WEB-SHEPHERD (3B).

6. Checklist质量对奖励预测的影响





Figure 7: Evaluation of checklist quality (left) and its relationship to reward accuracy (right).

Figure 7研究两个问题：

1. 不同模型生成的Checklist质量如何？
2. Checklist质量提高后，过程奖励模型能否更准确地排序候选动作？

左图：评价不同模型生成的Checklist质量

作者使用GPT-4o作为评审模型，将生成的Checklist与参考Checklist进行比较，并从以下三个方面打1~5分：

- **Validity**：是否包含错误或无关的子目标
- **Subgoal Granularity**：子目标粒度是否合适
- **Goal Coverage**：是否覆盖完成任务所需的关键步骤

右图：Checklist质量是否影响奖励预测？

作者准备四种Checklist：

- **A**：低质量Checklist
- **B**：Web-Shepherd (8B) 生成的Checklist
- **C**：Checklist-only模型生成的Checklist

- **D**: 人工标注的Ground Truth Checklist

然后分别提供给两个奖励模型：GPT-4o-mini Web-Shepherd (3B)
让它们对候选动作进行评分，并使用MRR评价正确动作的排序位置




Figure 8: Analysis on the training objective.

- **目的**: 验证Web-Shepherd的训练目标是否优于传统Bradley-Terry (BT) 目标
- **设置**: 使用相同训练数据训练两个奖励模型：
 - **BT模型**: 学习让正确动作的分数高于错误动作
 - **Web-Shepherd**: 生成文字反馈和Checklist状态，再计算动作奖励