

# A-Mem

## 一、A-Mem: Agentic Memory for LLM Agents

<https://arxiv.org/abs/2502.12110>

### 1.agent的旧记忆来源

实际应用：用户与智能体交互

本文实验：数据集中的对话记录

一轮对话里的一次发言=新记忆

### 2.现有具体方法

LoCoMo <https://arxiv.org/abs/2402.17753>

最简单粗暴的方法——不做任何记忆处理。直接把完整的对话历史全部塞进 LLM 的 prompt 里，让 LLM 自己在里面找答案

ReadAgent <https://arxiv.org/abs/2402.09727>

三步处理。第一步把长对话切成小块（分页）。第二步让 LLM 把每个小块压缩成一句话的摘要（要点提取）。第三步回答问题时，先根据摘要定位到相关的原文块，再去读原文回答

MemoryBank <https://arxiv.org/abs/2305.10250>

引入遗忘机制，模拟艾宾浩斯遗忘曲线。每条记忆有一个强度值，越久远、越不重要的记忆强度越低  $e^{(-s/t)}$

MemGPT <https://arxiv.org/abs/2310.08560>

借鉴操作系统的虚拟内存架构。把记忆分两层：上下文窗口（类比主存）是 LLM 当前能看到的部分，外部数据库（类比磁盘）存储超出窗口的历史。系统自动决定什么时候把信息从外部换入主上下文，什么时候把不紧急的信息换出

### 3.数据的结构

单条记忆 类的实例（MemoryNote）

例：

```
note_001 = MemoryNote(  
content="Dave最近开始学习摄影，经常拍摄附近的风景。",  
timestamp="2023-11-17 10:54",  
keywords=["摄影", "风景", "爱好"],  
tags=["个人爱好", "摄影", "休闲活动"],  
context="Dave开始培养摄影爱好，主要拍摄当地风景。",  
links=[]  
)
```

记忆库 字典（dict）

例：

```
note_002 = MemoryNote(  
content="Dave准备下个月去黄石公园拍摄瀑布和野生动物。",  
timestamp="2023-12-02 09:30",  
keywords=["黄石公园", "摄影", "瀑布", "野生动物"],  
tags=["旅行", "摄影", "自然风景"],  
context="Dave计划前往黄石公园进行自然风景摄影。",  
links=["mem_001"]  
)
```

```
memory_store = {  
"mem_001": note_001,  
"mem_002": note_002  
}
```

```
memory_store["mem_001"].links = ["mem_002"]  
memory_store["mem_002"].links = ["mem_001"]
```

```
memory_array = list(memory_store.values())
```

嵌入向量 数组

```
embedding_matrix = [  
[0.82, 0.71, 0.15, 0.32], # mem_001  
[0.79, 0.74, 0.42, 0.35] # mem_002  
]
```

```
embedding_matrix[0] → memory_store["mem_001"]  
embedding_matrix[1] → memory_store["mem_002"]
```

## 1.motivation

现有的 LLM Agent 记忆系统太"死板"，无法灵活地组织和更新记忆

第一，记忆操作是预定义的，遇到新类型的任务或知识，这些固定规则就不适用（四种前人方法）

第二，记忆存进去之后保持静态，缺乏"记忆随经验演化"的能力

例:系统中原来有一条记忆：

记忆1：

content：用户每天早上都喜欢喝咖啡。

context：用户有每天早晨喝咖啡的习惯。

keywords: 咖啡、喜欢、早晨习惯

tags: 饮食偏好、生活习惯

一个月后，用户产生了一条新记忆：

记忆2:

content: 医生认为喝咖啡会影响用户的睡眠，建议用户停止饮用，用户现在已经不喝咖啡

context: 用户因为睡眠问题，已经按照医生的建议停止喝咖啡。

keywords: 咖啡、睡眠、医生建议、停止饮用

tags: 健康、睡眠、饮食变化

如果不进行记忆演化，记忆1仍然表示“用户喜欢喝咖啡”，记忆2则表示“用户现在已经不喝咖啡”。两条记忆虽然可以建立链接，但记忆1的context、keywords和tags不会发生变化。当用户询问“请给我推荐一种早晨饮品”时，如果系统只检索到记忆1，LLM可能错误地推荐咖啡；如果同时检索到两条记忆，LLM还需要根据时间和内容自行判断哪一条代表用户的当前状态。

进行记忆演化，利用记忆2更新记忆1的语义属性：

演化后的记忆1:

content: 用户每天早上都喜欢喝咖啡。（原始内容保留）

context: 这是用户过去的饮食偏好；后来因为咖啡影响睡眠，用户已按照医生的建议停止饮用。

keywords: 咖啡、过去偏好、睡眠、停止饮用

tags: 历史偏好、健康变化

记忆2仍然保留:

content: 医生认为喝咖啡会影响用户的睡眠，建议用户停止饮用，用户现在已经不喝咖啡。

context: 用户当前已经停止喝咖啡。

keywords: 咖啡、睡眠、医生建议、停止饮用

tags: 健康、睡眠、当前状态

## 2.具体方法

### (1) Note Construction

处理流程:

1) 输入原始信息:  $c$ (对话内容)  $t$ (时间戳)

2) LLM根据提示词生成:  $K$ (关键词)  $G$ (标签)  $X$ (上下文描述)

3) 将content keywords tag context拼接，送入编码器all-MiniLM-L6-v2生成 $e$ (向量)

$L$ (链接集合) 链接集合在第二步生成

输入: 时间戳+对话内容

输出: Python对象

例：

输入：

时间戳 (t<sub>i</sub>): 10:54 am on 17 November, 2023

原始内容 (c<sub>i</sub>): Speaker Dave says: "Hey Calvin, long time no talk!  
A lot has happened. I've taken up photography and it's been great  
been taking pics of the scenery around here which is really cool."

输出：

python对象

```
note = MemoryNote(  
content='Speaker Dave says: "Hey Calvin, long time no talk! ...',  
timestamp='10:54 am on 17 November, 2023',  
keywords=['photography', 'scenery', 'conversation', 'experience', 'hobby'],  
tags=['hobby', 'photography', 'personal development', 'conversation', 'leisure'],  
context="The main topic is the speaker's new hobby of photography...",  
links=[]  
)
```

embedding后的向量存储在另一个数组中，同一条记忆的向量数组和对象实例数组下标相同

## (2) Link Generation

输入：Note Construction的输出+旧笔记的集合

处理结果：新记忆的link已填充好

处理流程：

- 1) 输入新笔记和旧笔记的向量，计算余弦相似度，以实现快速粗筛，根据结果选出k个旧笔记的集合
- 2) 调用API，将新笔记+top-k旧笔记集合+提示词输入LLM，LLM决定新记忆与哪些旧记忆产生链接  
link中存储旧记忆的ID
- 3) py代码按照LLM的输出修改link

## (3) Memory Evolution

输入：新笔记+粗筛选出的旧笔记集合

输出：旧笔记集合中某些笔记的 context、keywords、被更新

处理流程：

- 1) 将需要处理的旧笔记+新笔记+Top-k集合中的其他候选记忆+提示词输入LLM，LLM返回旧笔记修改之后的context+keywords
- 2) py代码按照LLM的输出修改旧笔记context、keywords

## (4)用户询问问题时的处理流程

当前问题 $q$ →词嵌入变为向量 $q$ →与所有记忆向量计算余弦相似度→按相似度排序→取Top-k条记忆→顺着links取出关联记忆→把问题和检索结果放入提示词→LLM生成答案

### 3.实验

#### (1)主实验

##### 1. 数据集：长对话+问题以及答案(DislSim还包括时序知识图谱)

LoCoMo：先看完对话，再问问题

离线评测方式，先将完整对话历史写入记忆系统，然后使用固定问题测试

问题：

1. **单跳问题**：可以根据一个session中的信息回答
2. **多跳问题**：需要综合多个session中的信息才能回答
3. **时间推理问题**：测试模型对时间相关信息理解能力
4. **开放领域知识问题**：需要将对话上下文与外部知识结合起来
5. **对抗性问题**：评估模型识别不可回答问题的能力

DislSim：一边看对话，一边问问题

在线模拟方式，在对话不断进行和记忆持续更新的过程中插入问题，测试智能体根据当前已有记忆进行回答的能力

(该数据集的作者未公布)时序知识图谱每条数据结构：(主体,关系,客体,时间)

问题：

6. easy\_q：根据电视剧剧情回答
7. hard\_q：根据时序知识图谱回答

##### 2. 评估指标：

- **F1 分数**：综合精确率和召回率，评价答案的准确性
- **BLEU-1**：通过计算生成答案与标准答案之间的词语重合程度，评价回答质量  
(文本文字精确匹配)
- **ROUGE-L**：基于最长公共子序列衡量生成文本与参考文本的重合度
- **ROUGE-2**：基于二元词组 (bigram) 重合度评价文本质量  
(文本局部顺序匹配)
- **METEOR**：考虑同义词和释义的匹配，比 BLEU 更灵活  
(语义匹配程度)
- **SBERT Similarity**：用句子嵌入计算语义相似度，即使用词不同也能捕捉含义相近  
(文本全局语义和顺序的匹配程度)

原文：A B C D E F

子串 (要求连续): B C D ☒ B D E ☒

子序列 (不要求连续): B D F ☒ F D B ☒

标准答案: Dave 最近 开始 学习 摄影 拍摄 风景 (7个词)

模型回答: Dave 开始了 摄影 并且 拍摄 周围 风景 (8个词)

LCS = "Dave 开始 摄影 拍摄 风景" (5个词)

Dave → ☒

最近 → 跳过

开始 → ☒

学习 → 跳过

摄影 → ☒

拍摄 → ☒

风景 → ☒

RI = 5/7 = 0.714

PI = 5/8 = 0.625

### 3. 模型:

GPT-4o-mini GPT-4o

Qwen2.5-1.5B Qwen2.5-3B

Llama 3.2-1B Llama 3.2-3B

| Model     |         | Method     | Category  |       |          |       |             |       |            |       |           |       | Average |      |              |
|-----------|---------|------------|-----------|-------|----------|-------|-------------|-------|------------|-------|-----------|-------|---------|------|--------------|
|           |         |            | Multi Hop |       | Temporal |       | Open Domain |       | Single Hop |       | Adversial |       | Ranking |      | Token Length |
|           |         |            | F1        | BLEU  | F1       | BLEU  | F1          | BLEU  | F1         | BLEU  | F1        | BLEU  | F1      | BLEU |              |
| GPT       | 4o-mini | LoCoMo     | 25.02     | 19.75 | 18.41    | 14.77 | 12.04       | 11.16 | 40.36      | 29.05 | 69.23     | 68.75 | 2.4     | 2.4  | 16,910       |
|           |         | READAGENT  | 9.15      | 6.48  | 12.60    | 8.87  | 5.31        | 5.12  | 9.67       | 7.66  | 9.81      | 9.02  | 4.2     | 4.2  | 643          |
|           |         | MEMORYBANK | 5.00      | 4.77  | 9.68     | 6.99  | 5.56        | 5.94  | 6.61       | 5.16  | 7.36      | 6.48  | 4.8     | 4.8  | 432          |
|           |         | MEMGPT     | 26.65     | 17.72 | 25.52    | 19.44 | 9.15        | 7.44  | 41.04      | 34.34 | 43.29     | 42.73 | 2.4     | 2.4  | 16,977       |
|           |         | A-MEM      | 27.02     | 20.09 | 45.85    | 36.67 | 12.14       | 12.00 | 44.65      | 37.06 | 50.03     | 49.47 | 1.2     | 1.2  | 2,520        |
|           | 4o      | LoCoMo     | 28.00     | 18.47 | 9.09     | 5.78  | 16.47       | 14.80 | 61.56      | 54.19 | 52.61     | 51.13 | 2.0     | 2.0  | 16,910       |
|           |         | READAGENT  | 14.61     | 9.95  | 4.16     | 3.19  | 8.84        | 8.37  | 12.46      | 10.29 | 6.81      | 6.13  | 4.0     | 4.0  | 805          |
|           |         | MEMORYBANK | 6.49      | 4.69  | 2.47     | 2.43  | 6.43        | 5.30  | 8.28       | 7.10  | 4.42      | 3.67  | 5.0     | 5.0  | 569          |
|           |         | MEMGPT     | 30.36     | 22.83 | 17.29    | 13.18 | 12.24       | 11.87 | 60.16      | 53.35 | 34.96     | 34.25 | 2.4     | 2.4  | 16,987       |
|           |         | A-MEM      | 32.86     | 23.76 | 39.41    | 31.23 | 17.10       | 15.84 | 48.43      | 42.97 | 36.35     | 35.53 | 1.6     | 1.6  | 1,216        |
| Qwen2.5   | 1.5b    | LoCoMo     | 9.05      | 6.55  | 4.25     | 4.04  | 9.91        | 8.50  | 11.15      | 8.67  | 40.38     | 40.23 | 3.4     | 3.4  | 16,910       |
|           |         | READAGENT  | 6.61      | 4.93  | 2.55     | 2.51  | 5.31        | 12.24 | 10.13      | 7.54  | 5.42      | 27.32 | 4.6     | 4.6  | 752          |
|           |         | MEMORYBANK | 11.14     | 8.25  | 4.46     | 2.87  | 8.05        | 6.21  | 13.42      | 11.01 | 36.76     | 34.00 | 2.6     | 2.6  | 284          |
|           |         | MEMGPT     | 10.44     | 7.61  | 4.21     | 3.89  | 13.42       | 11.64 | 9.56       | 7.34  | 31.51     | 28.90 | 3.4     | 3.4  | 16,953       |
|           |         | A-MEM      | 18.23     | 11.94 | 24.32    | 19.74 | 16.48       | 14.31 | 23.63      | 19.23 | 46.00     | 43.26 | 1.0     | 1.0  | 1,300        |
|           | 3b      | LoCoMo     | 4.61      | 4.29  | 3.11     | 2.71  | 4.55        | 5.97  | 7.03       | 5.69  | 16.95     | 14.81 | 3.2     | 3.2  | 16,910       |
|           |         | READAGENT  | 2.47      | 1.78  | 3.01     | 3.01  | 5.57        | 5.22  | 3.25       | 2.51  | 15.78     | 14.01 | 4.2     | 4.2  | 776          |
|           |         | MEMORYBANK | 3.60      | 3.39  | 1.72     | 1.97  | 6.63        | 6.58  | 4.11       | 3.32  | 13.07     | 10.30 | 4.2     | 4.2  | 298          |
|           |         | MEMGPT     | 5.07      | 4.31  | 2.94     | 2.95  | 7.04        | 7.10  | 7.26       | 5.52  | 14.47     | 12.39 | 2.4     | 2.4  | 16,961       |
|           |         | A-MEM      | 12.57     | 9.01  | 27.59    | 25.07 | 7.12        | 7.28  | 17.23      | 13.12 | 27.91     | 25.15 | 1.0     | 1.0  | 1,137        |
| Llama 3.2 | 1b      | LoCoMo     | 11.25     | 9.18  | 7.38     | 6.82  | 11.90       | 10.38 | 12.86      | 10.50 | 51.89     | 48.27 | 3.4     | 3.4  | 16,910       |
|           |         | READAGENT  | 5.96      | 5.12  | 1.93     | 2.30  | 12.46       | 11.17 | 7.75       | 6.03  | 44.64     | 40.15 | 4.6     | 4.6  | 665          |
|           |         | MEMORYBANK | 13.18     | 10.03 | 7.61     | 6.27  | 15.78       | 12.94 | 17.30      | 14.03 | 52.61     | 47.53 | 2.0     | 2.0  | 274          |
|           |         | MEMGPT     | 9.19      | 6.96  | 4.02     | 4.79  | 11.14       | 8.24  | 10.16      | 7.68  | 49.75     | 45.11 | 4.0     | 4.0  | 16,950       |
|           |         | A-MEM      | 19.06     | 11.71 | 17.80    | 10.28 | 17.55       | 14.67 | 28.51      | 24.13 | 58.81     | 54.28 | 1.0     | 1.0  | 1,376        |
|           | 3b      | LoCoMo     | 6.88      | 5.77  | 4.37     | 4.40  | 10.65       | 9.29  | 8.37       | 6.93  | 30.25     | 28.46 | 2.8     | 2.8  | 16,910       |
|           |         | READAGENT  | 2.47      | 1.78  | 3.01     | 3.01  | 5.57        | 5.22  | 3.25       | 2.51  | 15.78     | 14.01 | 4.2     | 4.2  | 461          |
|           |         | MEMORYBANK | 6.19      | 4.47  | 3.49     | 3.13  | 4.07        | 4.57  | 7.61       | 6.03  | 18.65     | 17.05 | 3.2     | 3.2  | 263          |
|           |         | MEMGPT     | 5.32      | 3.99  | 2.68     | 2.72  | 5.64        | 5.54  | 4.32       | 3.51  | 21.45     | 19.37 | 3.8     | 3.8  | 16,956       |
|           |         | A-MEM      | 17.44     | 11.74 | 26.38    | 19.50 | 12.53       | 11.83 | 28.14      | 23.87 | 42.04     | 40.60 | 1.0     | 1.0  | 1,126        |


GPT本身能处理较长的上下文，较小的Qwen或Llama难以有效处理这么长的上下文，因此使用A-MEM的收益十分明显

(2)消融实验

移除LG和ME 移除ME 完整A-MEM

| Method      | Category  |        |          |        |             |        |            |        |             |        |
|-------------|-----------|--------|----------|--------|-------------|--------|------------|--------|-------------|--------|
|             | Multi Hop |        | Temporal |        | Open Domain |        | Single Hop |        | Adversarial |        |
|             | F1        | BLEU-1 | F1       | BLEU-1 | F1          | BLEU-1 | F1         | BLEU-1 | F1          | BLEU-1 |
| w/o LG & ME | 9.65      | 7.09   | 24.55    | 19.48  | 7.77        | 6.70   | 13.28      | 10.30  | 15.32       | 18.02  |
| w/o ME      | 21.35     | 15.13  | 31.24    | 27.31  | 10.13       | 10.85  | 39.17      | 34.70  | 44.16       | 45.33  |
| A-MEM       | 27.02     | 20.09  | 45.85    | 36.67  | 12.14       | 12.00  | 44.65      | 37.06  | 50.03       | 49.47  |

(3)检索参数k



(4)Memory Analysis

t-SNE处理，将embedding降到二维平面可视化

