

ACE-SKILL

ACE-SKILL: Bootstrapping Multimodal Agents with Prioritized and Clustered Evolution

论文: [arXiv:2605.08887](https://arxiv.org/abs/2605.08887)

作者: Feng Xiong、Zengbin Wang、Yong Wang、Xuecai Hu、Jinghan He、Liang Lin、Yuan Liu、Xiangxiang Chu

机构: AMAP、Alibaba Group、CASIA、Beijing Normal University

代码: [AMAP-ML/Ace-Skill](https://github.com/AMAP-ML/Ace-Skill)

数据: [TIR-Bench](#)、[VisualToolBench](#)、[MMSearch-Plus](#)、[AgentVista](#)

前置阅读: XSkill




Figure 2: Overview of the ACE-SKILL framework. ACE-SKILL breaks the vicious cycle between data inefficiency and knowledge interference through a prioritized sampler and a clustered organizer.

Problem (文章要解决什么问题?)

1. **有限计算资源如何分配**: 哪些样本值得反复探索, 哪些已经基本掌握、不必继续投入大量 rollout?
2. **积累的知识如何组织**: 怎样避免不同任务类型的经验混在一起, 在检索时互相干扰?
在固定训练预算下, 把更多计算投入当前最有学习价值的样本, 并将产生的经验和技能按任务类别隔离组织, 使智能体能够更有效地学习和调用知识

Gap (现有研究的缺陷、痛点)

1. 训练资源平均分配, 浪费 rollout 预算

以 XSkill 为例，简单题和困难题通常使用相同数量的 rollout。实际上：

- 简单题可能执行少量轨迹就已经掌握；
 - 困难题可能需要更多轨迹才能探索出有效方法；
 - 继续重复已经掌握的任务会浪费计算资源；
 - 真正具有学习价值的困难或结果不稳定任务反而探索不足
- 现有方法缺少一种能够随智能体能力变化而动态调整的训练样本选择机制

2. 不同任务的知识存放在一起，容易产生干扰

经验库中可能同时包含：

- OCR 文字识别；
- 迷宫和网格推理；
- 网页搜索；
- 代码生成；
- GUI 操作

当智能体解决迷宫任务时，全局检索可能返回图像预处理或字符识别经验。真正相关的知识会被噪声稀释，导致智能体选错工具或走错推理路径

Core idea（文章的核心思想、insight）

1. **Prioritized Evolution（优先进化）**：根据每条样本当前的掌握度，优先采样结果不稳定、尚未掌握或需要继续探索的任务
 2. **Clustered Evolution（聚类进化）**：先对任务进行语义聚类，再为每个类别分别维护经验池和技能文档，减少跨类别知识干扰
- 论文的核心 insight 是：

智能体自进化的关键不只是生成更多轨迹，而是将有限轨迹预算分配给更有学习价值的任务，并让知识在相对一致的任务类别内部积累和复用。

How（文章核心方法如何设计）

1. 样本表示与语义聚类

一条训练样本表示为：

$$x_i = (I_i, Q_i, A_i)$$

其中：

- I_i ：任务图像；
- Q_i ：任务问题；

- A_i : 标准答案。

训练开始前，系统提取问题文本 Q_i 的 embedding，再使用 K-means 将训练样本划分为 K 个语义簇

输入： 训练集中的问题文本 Q_i 和样本编号 `doc_id`

输出： 每条样本的 `cluster_id` 以及各簇的聚类中心

执行者： Embedding 模型与程序代码

聚类结构在训练开始前确定。训练和测试时，新任务被路由到距离最近的聚类中心：

$$c(x) = \arg \min_k \|f(Q) - \mu_k\|^2$$

其中， $f(Q)$ 是问题文本向量， μ_k 是第 k 个聚类中心

2. 初始化样本状态与聚类知识库

每个知识簇表示为：

$$C_k = (E_k, S_k)$$

其中：

- E_k : 战术经验池，保存实例级、短文本形式的经验；
- S_k : 战略技能文档，保存类别级、Markdown 形式的工作流。

训练开始前初始化：

$$E_k = \emptyset, \quad S_k = \emptyset$$

同时，为每条样本维护三个数值状态：

$$\alpha_i = 0, \quad \beta_i = 0, \quad t_i = 0$$

其中：

- α_i : 该样本积累的成功次数；
- β_i : 该样本积累的失败次数；
- t_i : 该样本上次被访问的时间

初始状态没有成功或失败证据，因此初始掌握度为 $v_i = 0.5$ 。

3. Prioritized Sampler: 优先采样

优先采样器在每个训练步开始时调用

3.1 计算延迟衰减后的掌握度

由于智能体会不断从其他任务中学习，较早的成功或失败记录可能已经过时。论文使用 Lazy Decay 对历史证据进行延迟衰减：

$$\tilde{\alpha}_i = \alpha_i \rho^{t-t_i}$$

$$\tilde{\beta}_i = \beta_i \rho^{t-t_i}$$

当前掌握度为：

$$v_i = \frac{1 + \tilde{\alpha}_i}{2 + \tilde{\alpha}_i + \tilde{\beta}_i}$$

其中：

- t ：当前训练时间；
- t_i ：上次访问样本 x_i 的训练时间；
- ρ ：时间衰减系数，论文取 0.95；
- v_i ：智能体当前解决样本 x_i 的估计成功概率

3.2 计算采样权重

$$w_t(x_i) = \sqrt{v_i(1 - v_i)} + \gamma(1 - v_i) + \epsilon$$

权重包含三部分：

- $\sqrt{v_i(1 - v_i)}$ ：不确定性。 v_i 接近 0.5 时较大，表示结果不稳定；
- $\gamma(1 - v_i)$ ：困难度。 v_i 越低，该项越大；
- ϵ ：基础探索，保证已经掌握的样本仍有最低采样机会。

3.3 按权重无放回采样

先将权重归一化：

$$p_t(x_i) = \frac{w_t(x_i)}{\sum_{j=1}^N w_t(x_j)}$$

再按照概率分布进行无放回采样：

$$\mathcal{B}_t \sim p_{\text{sample}}(\mathcal{D}, \mathbf{V})$$

输出本轮训练样本集合 $\mathcal{B}_t$ 。论文设置 batch size 为 $B = 8$ 。

4. 知识增强 Rollout

对 batch 中的每条样本执行以下过程：

1. 根据固定路由规则确定样本所属知识簇；
2. 在该簇的 E_k 中进行向量相似度检索；
3. 读取该簇完整的 Skill 文档 S_k ；

4. 大模型根据当前任务对 Skill 进行适配；
5. 将经验、技能、图像和问题共同输入智能体；
6. 智能体进行多轮推理与工具调用；
7. 得到完整执行轨迹和最终预测答案

执行轨迹包括模型每轮文本输出、工具名称、工具参数、工具返回结果以及最终答案

5. 验证结果并提取知识

验证器比较预测答案和标准答案 A_i ，得到奖励： r_i 取0/1

随后，大模型分析执行轨迹、工具调用和验证结果，提取：skill和experience

程序负责路由、检索和结果保存；智能体大模型负责任务执行和工具调用；验证器负责奖励判断；大模型负责轨迹反思与知识提取。

6. 更新样本掌握度

只更新本轮被采样样本的状态：

$$\alpha_i \leftarrow \tilde{\alpha}_i + r_{t,i}$$

$$\beta_i \leftarrow \tilde{\beta}_i + (1 - r_{t,i})$$

$$t_i \leftarrow t$$

如果样本连续成功， v_i 会逐渐升高，后续采样概率下降；如果样本持续失败，困难度项会使其获得更多训练机会

7. 更新 Experience 和 Skill

Experience 更新

程序计算新经验与同簇已有经验的向量相似度：

- 没有相似经验：直接插入新经验；
- 存在相似经验：将新经验与相似经验交给大模型合并；
- 经验池超过容量：进一步合并最相似的经验，控制知识库大小

Skill 更新

程序把以下内容输入大模型：

- 旧 Skill 文档；
 - 当前轨迹提取的新 Skill；
 - 作者编写的 Skill 合并提示词
- 大模型输出更新后的完整 Markdown 技能文档

Evidence (实验、证据、消融)

1. 实验设置

论文在四个多模态工具使用基准上进行实验：

- **TIR-Bench**：以代码执行为主的工具集成推理任务；
- **VisualToolBench**：视觉场景下的工具选择与执行；
- **MMSearch-Plus**：复杂多模态网页搜索；
- **AgentVista**：GUI、操作系统和网页应用中的长程任务。

智能体可以使用四类工具：

- **Code Interpreter**：有状态的 Python/Jupyter 环境，用于数学计算、数据分析、代码执行和图像处理；
- **Image Search**：支持文字搜图和反向图片搜索；
- **Web Search**：根据关键词返回网页标题、链接和摘要；
- **Visit**：访问具体网页、提取正文并生成与任务相关的摘要。

主要指标为：

- **Avg@4**：每道题独立运行四次后的平均成功率；
- **Pass@4**：四次中至少成功一次的样本比例。

2. 主实验结果

使用 Qwen3.5-35B-A3B 作为 backbone 时：

相对于 Vanilla Tools，ACE-Skill 的 Mean Avg@4 提升 8.22，Mean Pass@4 提升 6.91
四个数据集上的 Avg@4 提升分别为：

- TIR-Bench：+10.63；
- VisualToolBench：+5.02；
- MMSearch-Plus：+11.96；
- AgentVista：+5.27

代码密集型的 TIR-Bench 和搜索密集型的 MMSearch-Plus 提升最大，说明经验和技能积累

对复杂工具推理尤其有效

Model	TIR-Bench		VisualToolBench		MMSearch-Plus		AgentVista		Mean	
	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4
Proprietary Multimodal Models										
o4-mini* (OpenAI, 2025a)	20.13	45.00	14.72	27.57	5.92	12.32	19.04	25.69	14.95	27.65
↪ Vanilla Tools	24.62	49.50	19.63	34.11	15.88	21.80	18.12	29.36	19.56	33.69
GPT-5-mini* (OpenAI, 2025b)	20.00	46.50	13.90	22.90	3.08	6.64	18.58	28.44	13.89	26.12
↪ Vanilla Tools	23.50	50.50	24.30	37.85	14.22	20.38	20.41	35.78	20.61	36.13
Gemini-2.5-Pro* (Comanici et al., 2025)	21.37	40.00	20.91	28.97	10.43	19.43	17.89	28.44	17.65	29.21
↪ Vanilla Tools	28.38	54.00	25.35	40.65	21.56	35.55	20.18	33.94	23.87	41.04
Qwen3.5-Plus (Qwen, Team, 2026)	29.88	47.50	17.17	28.04	6.64	10.43	11.47	18.35	16.29	26.08
↪ Vanilla Tools	40.25	62.50	29.21	49.07	27.84	46.45	16.74	31.19	28.51	47.30
Open-Source Multimodal Models										
GLM-4.6V (GLM, Team, 2026)	17.50	28.00	17.76	34.11	3.67	8.06	15.14	24.77	13.52	23.74
↪ Vanilla Tools	18.75	42.00	15.89	31.78	17.42	34.60	15.60	31.19	16.92	34.89
Kimi-K2.5 (Team et al., 2026)	17.37	28.00	12.85	19.63	10.78	18.48	18.12	30.28	14.78	24.10
↪ Vanilla Tools	19.38	37.00	21.03	34.11	33.53	48.34	18.35	31.19	23.07	37.66
Baseline and ACE-SKILL										
Qwen3.5-35B-A3B (Qwen, Team, 2026)	23.00	43.00	15.65	28.04	3.67	7.58	10.32	17.43	13.16	24.01
↪ Vanilla Tools	39.37	65.00	21.38	39.72	16.59	28.44	15.37	32.11	23.18	41.32
↪ w/ XSkill (Jiang et al., 2026b)	40.62	68.00	22.43	35.51	23.93	41.23	16.51	29.36	25.87	43.53
↪ w/ ACE-SKILL	50.00	71.50	26.40	41.59	28.55	43.13	20.64	36.70	31.40	48.23

3. 模型规模扩展与跨模型迁移

在 Qwen3.5-122B-A10B 上：

- Vanilla Tools：Mean Avg@4 为 28.70；
- ACE-Skill：Mean Avg@4 为 33.49

将在35B模型上积累的知识直接迁移给更小模型且不重新训练

说明 ACE-Skill 积累的文本经验和技能具有一定的模型规模迁移能力，但并非所有单项指标都提升

Table 3: Scalability and zero-shot transfer results (Avg@4 and Pass@4). Top: scaling ACE-SKILL to Qwen3.5-122B-A10B. Bottom: directly injecting knowledge bootstrapped by 35B-A3B into smaller models (9B, 4B) without retraining. **Bold** indicates the best result.

Model	TIR-Bench		VisualToolBench		MMSearch-Plus		AgentVista		Mean	
	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4	Avg@4	Pass@4
Exploring More Scalable Model (122B-A10B)										
Qwen3.5-122B-A10B (Qwen, Team, 2026)	22.13	41.00	13.90	22.90	4.03	9.48	9.86	18.35	12.48	22.93
↪ Vanilla Tools	46.12	74.50	23.83	40.19	29.23	45.97	15.60	31.19	28.70	47.96
↪ w/ ACE-SKILL	53.12	75.00	29.44	50.47	33.06	49.29	18.35	33.03	33.49	51.95
Transfer Evaluations of Experiences and Skills (35B-A3B → 9B, 4B)										
Qwen3.5-9B (Qwen, Team, 2026)	14.75	28.50	10.16	21.03	1.66	4.27	4.59	11.93	7.79	16.43
↪ Vanilla Tools	26.75	50.50	18.11	34.11	14.45	27.49	9.17	22.94	17.12	33.76
↪ w/ ACE-SKILL	39.62	66.00	20.56	35.51	24.53	37.91	17.43	33.03	25.54	43.11
Qwen3.5-4B (Qwen, Team, 2026)	10.25	28.50	5.96	14.49	0.59	1.42	4.59	12.84	5.35	14.31
↪ Vanilla Tools	25.12	46.00	12.85	30.37	14.10	26.54	8.03	22.02	15.03	31.23
↪ w/ ACE-SKILL	33.50	61.50	15.07	29.91	19.31	29.38	11.93	22.94	19.95	35.93

4. 跨数据集零样本迁移

知识只在源数据集上积累，然后直接用于未参与知识积累的目标数据集：

- VisualToolBench → TIR-Bench：35B 模型 Avg@4 提升 6.13，122B 模型提升 4.13；
- MMSearch-Plus → AgentVista：35B 模型提升 3.21，122B 模型提升 4.35。

这说明聚类经验和技能能够迁移到部分相关但分布不同的工具任务

Table 4: Cross-domain generalization (OOD) performance (Avg@4). Experiences and skills are bootstrapped *only* on the source benchmark and directly transferred to a held-out target benchmark *without* any additional training or adaptation on the target domain. Δ denotes the absolute improvement over Vanilla Tools.

Model	VisualToolBench → TIR-Bench		MMSearch-Plus → AgentVista	
	Avg@4	Δ	Avg@4	Δ
Qwen3.5-35B-A3B (Qwen, Team, 2026)	39.37	-	15.37	-
↪ + OOD Transfer	45.50	+6.13	18.58	+3.21
Qwen3.5-122B-A10B (Qwen, Team, 2026)	46.12	-	15.60	-
↪ + OOD Transfer	50.25	+4.13	19.95	+4.35

5. 优先采样确实产生了非均匀训练分配

四个训练 epoch 后，不同样本被采样的频率明显不同：

这证明优先采样器没有像均匀训练那样让每条样本固定出现四次，而是把预算重新分配给不稳定或困难样本




Figure 3: Per-sample selection frequency of the Prioritized Evolution Sampler over 4 epochs on four benchmarks. Under uniform sampling, every sample would be visited exactly 4 times.

6. 模块级消融

在 TIR-Bench 上：

优先采样和聚类组织单独使用都有效，组合后效果最好，说明两个模块存在互补关系




Figure 4: Ablation of proposed modules on TIR-Bench (Avg@4). Left: Qwen3.5-35B-A3B. Right: Qwen3.5-122B-A10B. Each module provides independent gains, and their combination (ACE-SKILL) yields super-additive improvement on both scales.

7. 组件级消融

在35B模型上，去掉 Skill 聚类造成的下降最大，说明类别级技能隔离是聚类知识组织的重要来源。

Conditions	Qwen3.5 35B-A3B	Qwen3.5 122B-A10B
Basemodel	23.00	22.13
w/ Vanilla Tools	39.37	46.12
w/ ACE-SKILL (Ours)	50.00	53.12
Ablation of Components		
w/o Base Exploration	48.88	52.00
w/o Difficulty Bias	47.50	51.25
w/o Skill Cluster	46.75	51.62
w/o Experience Cluster	48.25	53.00

8. 超参数敏感性

困难度系数 γ :

- $\gamma = 0.4$ 时结果最好，Avg@4 为 50.0；
- 系数过大时会过度关注困难任务， $\gamma = 0.6$ 时下降到 44.5

时间衰减系数 ρ :

- $\rho = 0.93$ 和 0.95 时结果最好，Avg@4 为 50.0；

- 衰减过快或过慢都会降低效果




Figure 5: Hyperparameter sensitivity on TIR-Bench (Avg@4). **Top:** difficulty bias γ ($\rho = 0.95$). **Bottom:** temporal decay ρ ($\gamma = 0.4$).

My takeaway (读完这篇论文个人的思考)

工作缺口：

1. 分类仅根据问题文本分类，当“问题文本相似度”与“实际工具流程相似度”不一致时，ACE-Skill 的固定单簇路由会在什么条件下失效？基于图像和工具计划的软多簇路由能否减少这种负迁移
例如：

问题为：

请完成图片中给出的任务。

但不同图片可能分别要求：

- OCR识别；
- 图表计算；
- 反向图片搜索；
- 网页信息核验；
- GUI操作

2. 没有解决experience和skill的存储容量较小问题

3. 没有判断写入的experience和skill是否可靠

4. 工作开始时分出的类别是固定的，在问题1的基础上如果新问题与旧有的类别十分不相似，要建立新的类别