

MemSyco-Bench

论文: [MemSyco-Bench: Benchmarking Sycophancy in Agent Memory](#)

作者: Zhishang Xiang、Zerui Chen、Yunbo Tang

机构: 厦门大学、吉林大学

代码: [XMUDeepLIT/MemSyco-Bench](#)

数据: [MemSyco-Bench Data](#)

榜单: [MemSyco-Bench Leaderboard](#)

Motivation (研究背景)

Memory-Induced Sycophancy, 记忆诱导的谄媚

与普通单轮谄媚不同, 这种错误具有跨会话特征: 错误倾向并不直接出现在当前提示中, 而是通过“历史对话—记忆写入—记忆检索—下游推理”这一链条持续影响智能体

Gap (现有研究的不足)

1. 现有记忆基准主要衡量“能否记住”, 而不是“记住之后是否使用得当”
2. 将检索相关性等同于决策有效性
3. 缺少对记忆适用边界的系统建模
用户偏好可能只对特定对象、任务、群体或时间段有效。现有系统通常缺少对这些作用域条件的表示与判断
4. 难以区分检索失败和记忆使用失败
模型回答错误可能是因为正确记忆没有被召回, 也可能是因为已经召回了正确材料, 却在推理阶段错误地服从了记忆。现有评测很少对二者进行拆分
5. 现有干预通常采用统一的“谨慎使用记忆”提示
但不同场景需要不同策略: 有时应忽略记忆, 有时应更新旧记忆, 有时又必须主动使用用户偏好。统一降低对记忆的信任, 会损害个性化能力

Problem (本文要解决的问题)

本文研究的核心问题是:

评测当智能体从长期记忆中检索出与当前任务相关的用户事实、信念和偏好时, 它能否正确判断这些记忆在当前决策中的作用, 而不是机械地服从它们?

Core idea（文章的核心思想、Insight）

记忆系统的目标不应只是检索相关信息，而应当根据记忆的证据地位、适用范围、时效性和当前任务需求，动态校准记忆在决策中的权重

也就是说，智能体不仅要回答：

“这条记忆与当前问题相关吗？”

还必须进一步判断：

“这条记忆在当前问题中应该被忽略、限制范围、服从、更新，还是仅作为个性化偏好使用？”

How（文章核心方法如何设计）

3.1 Memory-Induced Sycophancy（记忆诱导谄媚）

系统从历史对话 D 提取事实记忆 M_f 和偏好记忆 M_p ，再为新查询 q 检索相关记忆并生成回答：
 $M = \text{Extract}(D) = M_f \cup M_p$, $R(q) = \text{Retrieve}(q, M)$, $y = G(q, R(q))$

3.2 Task Taxonomy（任务分类）

作者设计了五个互补任务，分别对应五种记忆处理策略

任务	记忆中包含的风险	正确策略
Objective Fact Judgment	用户过去的信念被误当作事实	ignore_as_evidence
Contextual Scope Control	偏好被错误推广到其他对象或场景	constrain_to_scope
Memory-Evidence Conflict	用户偏好与当前可靠证据冲突	defer_to_evidence
Valid Memory Selection	旧记忆与新记忆同时存在	update
Personalized Memory Use	有效偏好没有被利用	use

Objective Fact Judgment（客观事实判断）

检验模型能否区分用户信念与客观事实：即使记忆称“悉尼是澳大利亚首都”，也应依据事实回答“堪培拉”

Contextual Scope Control（上下文作用域控制）

检验模型能否遵守偏好的适用范围：个人的“尽早开始、快速决策”偏好不能直接套用于集体安排

Memory-Evidence Conflict（记忆与证据冲突）

检验记忆与当前证据冲突时能否以证据为准：若当前结果显示 Boreal 更准确，就不应因用户偏好 Atlas 而改选 Atlas

Valid Memory Selection（有效记忆选择）

检验新旧记忆冲突时能否采用最新状态：例如用“开始学习理论”的新偏好替代“不喜欢理论”的旧偏好


Personalized Memory Use（个性化记忆使用）

检验模型能否在记忆有效时主动个性化：例如依据用户偏好的慢节奏、重人物塑造推荐作品，而非完全忽略记忆

3.3 Benchmark Construction（基准构建）

MemSyco-Bench 共包含 1,550 个样本：

任务	样本数
Objective Fact Judgment	300
Contextual Scope Control	300
Memory-Evidence Conflict	300
Valid Memory Selection	350
Personalized Memory Use	300
总计	1,550



数据构建分为四个主要阶段：

Memory-decision schema construction

为每个样本定义任务目标、必要信息、记忆作用以及正确与谄媚答案，从而明确决策边界

Question instantiation

根据决策模式生成具体问题，其中更新任务包含新旧偏好，证据冲突任务包含支持正确答案的当前证据

Multi-turn dialogue simulation

将目标记忆嵌入约 10 轮模拟对话，再以新查询提出最终问题；用户和助手模拟器均不知道目标答案与失败方向，以减少信息泄露

Multi-stage validation

自动验证语义相关性、决策边界、失败方向和对话质量；GPT-5.5 参与模式草拟、问题生成、对话模拟及一致性检查

3.4 Evaluation Rubrics and Metrics（评测规则与指标）

指标	适用任务	衡量内容
Generation Accuracy	全部任务	回答是否符合目标答案和记忆使用边界
Sycophancy Rate	前三类任务	是否在不该服从记忆时沿着记忆的误导方向回答
Correct Memory Use	Personalized Memory Use	是否正确利用有效记忆进行个性化
Outdated Memory Use	Valid Memory Selection	是否继续服从已经过时的记忆

4.Experiment

4.1 整体性能（Q1）

问题： 现有记忆系统能否在利用长期记忆的同时避免谄媚？
作者在 Qwen3-8B 和 DeepSeek-V4-Flash 上评测七种记忆系统

Table 1: Main results on MemSyco-Bench. Each task reports accuracy and its corresponding memory-related metric. For OBJECTIVE FACT JUDGMENT, changes are computed against *No Memory*; for all other tasks, changes are computed against *Full Dialog*. (+) indicates improvement in the desired direction, and (-) indicates degradation. The whole results is on Table 3.


Method	Objective Fact Judgment		When to Use Memory Contextual Scope Control		Memory-Evidence Conflict		How to Use Memory Personalized Memory Use		Valid Memory Selection	
	Acc. ↑	Syco. Rate ↓	Acc. ↑	Syco. Rate ↓	Acc. ↑	Syco. Rate ↓	Acc. ↑	Correct Mem. Use ↑	Acc. ↑	Outdated Mem. ↓
Qwen3-8B										
No Memory	49.12	27.43	—	—	—	—	—	—	—	—
Full Dialog	30.62 (-18.50)	44.67 (+17.24)	70.00	24.67	0.67	99.33	45.67	63.34	27.79	56.16
NaiveRAG (Lewis et al., 2020)	34.00 (-15.12)	46.00 (+18.57)	52.33 (-17.67)	36.67 (+12.00)	17.00 (+16.33)	83.00 (-16.33)	51.67 (+6.00)	71.00 (+7.66)	30.40 (+2.61)	59.34 (+3.18)
Mem0 (Chhikara et al., 2025)	35.67 (-13.45)	46.01 (+18.58)	13.34 (-56.66)	27.00 (+2.33)	21.33 (+20.66)	69.00 (-30.33)	52.33 (+6.66)	64.00 (+0.66)	32.57 (+4.78)	59.14 (+2.98)
A-Mem (Xu et al., 2026b)	36.00 (-13.12)	44.47 (+17.04)	53.06 (-16.94)	35.03 (+10.36)	25.91 (+25.24)	73.63 (-25.70)	55.33 (+9.66)	71.00 (+7.66)	24.00 (-3.79)	64.85 (+8.69)
LightMem (Fang et al., 2025)	34.67 (-14.45)	55.00 (+27.57)	13.67 (-56.33)	23.33 (-1.34)	2.34 (+1.67)	77.93 (-21.40)	48.16 (+2.49)	67.56 (+4.22)	24.07 (-3.72)	69.91 (+13.75)
MemGPT (Packer et al., 2023)	30.00 (-19.12)	60.67 (+33.24)	40.00 (-30.00)	51.67 (+27.00)	3.72 (+3.05)	95.61 (-3.72)	46.33 (+0.66)	64.00 (+0.66)	41.14 (+13.35)	53.71 (-2.45)
MemoryBank (Zhong et al., 2024)	31.67 (-17.45)	55.00 (+27.57)	51.33 (-18.67)	43.33 (+18.66)	13.67 (+13.00)	86.33 (-13.00)	49.33 (+3.66)	62.33 (-1.01)	40.86 (+13.07)	50.57 (-5.99)
SuperMemory (Supermemory AI, 2026)	26.00 (-23.12)	64.67 (+37.24)	34.67 (-35.33)	57.00 (+32.33)	0.00 (-0.67)	99.33 (+0.00)	54.52 (+8.85)	73.58 (+10.24)	42.00 (+14.21)	53.14 (-3.02)
DeepSeek-V4-Flash										
No Memory	74.33	18.67	—	—	—	—	—	—	—	—
Full Dialog	61.67 (-12.66)	32.67 (+14.00)	79.00	17.00	59.67	40.33	60.34	79.33	77.67	16.34
NaiveRAG (Lewis et al., 2020)	59.33 (-15.00)	37.67 (+19.00)	79.00 (+0.00)	19.33 (+2.33)	84.28 (+24.61)	15.72 (-24.61)	49.00 (-11.34)	74.33 (-5.00)	78.29 (+0.62)	22.00 (+5.66)
Mem0 (Chhikara et al., 2025)	63.37 (-10.96)	32.52 (+13.85)	28.00 (-51.00)	21.00 (+4.00)	41.67 (-18.00)	51.00 (+10.67)	55.33 (-5.01)	76.00 (-3.33)	56.85 (-20.82)	41.42 (+25.08)
A-Mem (Xu et al., 2026b)	61.05 (-13.28)	32.00 (+13.33)	83.00 (+4.00)	15.00 (-2.00)	82.55 (+22.88)	17.44 (-22.89)	58.34 (-2.00)	78.00 (-1.33)	73.35 (-4.32)	23.78 (+7.44)
LightMem (Fang et al., 2025)	58.67 (-15.66)	39.00 (+20.33)	33.33 (-45.67)	19.67 (+2.67)	4.33 (-55.34)	79.67 (+39.34)	35.00 (-25.34)	64.67 (-14.66)	51.43 (-26.24)	48.57 (+32.23)
MemGPT (Packer et al., 2023)	56.33 (-18.00)	42.67 (+24.00)	69.67 (-9.33)	21.67 (+4.67)	34.67 (-25.00)	64.33 (+24.00)	38.33 (-22.01)	61.67 (-17.66)	74.57 (-3.10)	22.86 (+6.52)
MemoryBank (Zhong et al., 2024)	59.00 (-15.33)	40.00 (+21.33)	80.00 (+1.00)	17.67 (+0.67)	52.67 (-7.00)	47.00 (+6.67)	48.67 (-11.67)	72.00 (-7.33)	74.29 (-3.38)	22.57 (+6.23)
SuperMemory (Supermemory AI, 2026)	59.33 (-15.00)	40.00 (+21.33)	74.33 (-4.67)	19.00 (+2.00)	0.67 (-59.00)	98.00 (+57.67)	42.33 (-18.01)	65.67 (-13.66)	73.43 (-4.24)	25.14 (+8.80)

结论： 现有系统擅长保存和检索记忆，但不能可靠判断记忆何时应该使用、限制或忽略

4.2 错误归因 (Q2)

问题： 错误来自没有检索到信息，还是检索后使用错误

作者按照“是否检索到必要信息 (R+/R-)”和“回答是否正确 (A+/A-)”将结果分为四类。Mem0、A-Mem 和 LightMem 的错误中约 61%–62% 属于 **R+/A-**，即已经检索到相关记忆或证据，但仍然回答错误




结论： 记忆系统的问题不只是“找不到”，更重要的是“找到后不会正确使用”

4.3 推理行为指导 (Q3)

问题： 简单提示能否减少记忆诱导的谄媚？
作者在 DeepSeek-V4-Flash 上测试两种提示：

- 1. **Memory caution**：提醒模型仅在适当情况下使用记忆
- 2. **“Are you sure?”**：要求模型重新确认答案



结论： 通用的谨慎提示存在“减少谄媚—损害个性化”的权衡，而简单追问“你确定吗”反而可能强化受记忆影响的答案

4.4 复杂场景诊断（Q4）

作者进一步分析两个最困难的场景。

记忆—证据冲突

有效记忆选择

Memory-Evidence Conflict						
Method	Evidence Only		Memory Only		Evidence + Memory	
	Share (%)	Acc. (%)	Share (%)	Acc. (%)	Share (%)	Acc. (%)
A-Mem	0.0	–	0.0	–	100.0	25.91
LightMem	0.0	–	89.0	0.0	2.0	0.0
Mem0	3.34	70.0	51.51	6.49	40.47	36.36

Valid Memory Selection						
Method	Old Only		Updated Only		Old + Updated	
	Share (%)	Acc. (%)	Share (%)	Acc. (%)	Share (%)	Acc. (%)
A-Mem	1.14	25.0	0.29	0.0	98.57	24.06
LightMem	70.57	12.15	1.14	0.0	24.29	35.29
Mem0	3.71	0.0	28.0	53.06	67.14	26.38

结论： 检索到正确信息并不等于能正确回答；系统还需要具备证据优先级判断和新旧记忆的时间仲裁能力