

Keep it InMind

论文: [Keep It InMind: Benchmarking the Implicit-Association Blind Spot in Agent Memory](#) (当前为 v1, 2026-07-27)

作者: Ruizhe Li、Mingxuan Du、Benfeng Xu、Zhendong Mao

机构: 中国科学技术大学、Metastone Technology

代码: [imlrz/InMind](#)

数据: [InMind 125-task dataset](#)

Problem

记忆的隐式关联

举个例子:

你以前告诉它: “我对坚果过敏。”

以后直接问: “我对什么过敏?” 它能答对。

但如果你问: “教我做马卡龙。” 它可能推荐杏仁粉, 完全没想到你的过敏问题

Gap (现有研究的缺陷、痛点)

现有记忆查询方法的 Gap

主流方法: 当前查询 → 根据问题-记忆相似度检索记忆 → LLM 推理回答

现有记忆 Benchmark 的 Gap

没有提供一套配对诊断, 来区分间接问题失败的三个原因:

1. 事实没有被保存
2. 模型不知道连接事实和问题的世界知识
3. 事实已经保存, 但在需要时没有被检索出来

Core idea (文章的核心思想、insight)

一条记忆对当前问题很重要, 并不意味着它与当前问题在语义上相似

现有系统先检索记忆、再让 LLM 推理; 但很多记忆是否相关, 只有借助 LLM 掌握的世界知识才能判断。因此, 关键记忆可能在 LLM 有机会识别其相关性之前, 就已经被检索器排除

How (文章核心方法如何设计)

1. 收集数据

参考 Anthropic 的研究报告: [How people ask Claude for personal guidance](#), 确定每个领域的占比

之后从公开数据库按确定的比例抽取3380个知识片段，保存：

知识片段文本

来源 URL

该片段在原始资料中的文本范围

2.任务生成

输入：判定规则+知识片段

输出：

如果可以：

```
{  
  "extractable": true, // 是否可以生成有效任务  
  "reason": "...", // 判断理由  
  "task": {  
    "entity_1": "...", // 用户的个人事实或状态  
    "entity_2": "...", // 后续查询的对象或情境  
    "relation": "...", // 两个实体之间的知识关系  
    "explanation": "...", // 该记忆为何会影响回答  
    "user_message": "...", // 用户陈述个人事实的消息  
    "assistant_message": "...", // 助手对个人事实的简短回应  
    "naive_query": "...", // 直接询问该事实的问题  
    "query": "...", // 隐式关联测试问题  
  }  
}
```

如果不可以，返回：

```
{  
  "extractable": false,  
  "reason": "...",  
  "task": null  
}
```

使用模型：以 Gemini 2.5 Flash 为主，另外使用 Claude Sonnet 4.6、Claude Opus 4.8 和 DeepSeek V4 Pro 扩展生成

结果：共生成1,000条候选任务

3.任务筛选

(1)相似度筛选

输入：

`user_message`：需要被记住的用户事实

`query`：后续的间接问题

如果任一种方法认为用户记忆与间接问题是明显匹配的，就删除该任务

使用一下两种方法判断：

- BM25：检测词汇重叠
- 余弦相似度：all-MiniLM-L6-v2分别编码user_message和query，并通过余弦相似度检测语义接近程度
筛选后得到300条

(2)背景冲突筛选

该背景来自LongMemEval-s的实例 0bc8ad93，包含47个会话、486条消息

输入：候选任务的user_message+会话+冲突判断提示词

例如：

- 背景中用户明确表示没有宠物，候选事实却说用户养猫
 - 背景中用户已被设定为护士，候选事实却涉及该用户参加飞行员体检
- 输出：
- 存在冲突：删除任务
 - 不存在冲突：保留并进入专家审核

将保留的任务交给人工判断：

输入：

- 经过前两步筛选后保留下来的候选任务
 - 生成该候选任务所依据的原始知识片段
- 可以保留、修改或拒绝每个候选任务
得到113个任务，之后由人工编写了12条任务最终得到125个问答任务

4.评测方法

所有任务都使用同一段固定的LongMemEval-s背景对话，包含47个会话、486条消息
对每条任务分别执行：

1. 处理前8个背景会话
2. 在第9个会话末尾插入该任务的记忆对话：
 - user_message：用户陈述个人事实
 - assistant_message：助手对此事实的回应
3. 继续处理剩余38个背景会话
4. 所有背景对话结束后，再提出测试问题
让目标事实经历大量后续对话干扰，测试它能否被长期保存并在需要时使用

两类问题：

naive_query：直接询问用户事实

作用：测试事实是否被保存，以及直接询问时能否被找回

query：与用户事实表面不相似的间接问题
作用：测试系统能否主动找回并应用相关记忆

被测记忆基线：会话 + 测试问题 → context

回答模型：context + 测试问题 → answer

Evidence（实验、证据、消融）

Table 1 Results (%) on the 125-task InMind benchmark: direct *Naive* recall, answer-blind *Target Recall* in the indirect-query context, and end-to-end *Application*. The Δ columns report percentage-point differences (Recall–Naive, Application–Recall, Application–Naive); muted coral and cyan-blue indicate negative and positive changes, with darker shading for larger magnitudes. The backbone receives the target memory in context and therefore has no naive-retrieval score.

System	Naive		Target	Recall	Application	$\Delta_{\text{Recall-Naive}}$	$\Delta_{\text{App.-Recall}}$	$\Delta_{\text{App.-Naive}}$
Backbone Control								
Backbone (GPT-5-mini)	–	100.0		84.0	–	–16.0		–
Naive RAG								
Dense (MiniLM) (Wang et al., 2020)	92.0	0.8		9.6	–91.2	+8.8		–82.4
Dense (emb3-large) (OpenAI, 2024a)	97.6	6.4		16.0	–91.2	+9.6		–81.6
BM25 (Robertson and Zaragoza, 2009)	53.6	3.2		9.6	–50.4	+6.4		–44.0
MiniLM								
A-RAG (Du et al., 2026)	97.6	5.6		4.8	–92.0	–0.8		–92.8
xMemory (Hu et al., 2026)	84.8	3.2		4.8	–81.6	+1.6		–80.0
Mem0 (Chhikara et al., 2025)	76.0	2.4		3.2	–73.6	+0.8		–72.8
A-Mem (Xu et al., 2025)	99.2	2.4		6.4	–96.8	+4.0		–92.8
HippoRAG 2 (Gutierrez et al., 2025)	93.6	0.8		8.8	–92.8	+8.0		–84.8
MemoryOS (Kang et al., 2025)	87.2	2.4		8.0	–84.8	+5.6		–79.2
text-embedding-3-large								
A-RAG (Du et al., 2026)	93.6	11.2		7.2	–82.4	–4.0		–86.4
xMemory (Hu et al., 2026)	91.2	6.4		6.4	–84.8	0.0		–84.8
Mem0 (Chhikara et al., 2025)	76.8	6.4		6.4	–70.4	0.0		–70.4
A-Mem (Xu et al., 2025)	100.0	12.0		9.6	–88.0	–2.4		–90.4
HippoRAG 2 (Gutierrez et al., 2025)	96.0	2.4		5.6	–93.6	+3.2		–90.4
MemoryOS (Kang et al., 2025)	96.8	7.2		14.4	–89.6	+7.2		–82.4

测评指标

三个核心指标均为二元判定，每个任务得 0 或 1 分，最终报告 125 个任务上的准确率
GPT-5-mini模型

1. Naive Recall（直接召回）

测试问题：naive_query，直接询问用户曾经陈述的事实
判定输入：

user_message + context + naive_query + answer

得 1 分需要同时满足：

- context 中包含目标个人事实
- answer 正确回答了该事实

作用：检验目标事实是否被保存，并能否在直接询问时被找回

2. Target Recall（目标记忆召回）

测试问题：间接 query

判定输入：

`user_message + context + query + explanation`

评测模型看不到最终 answer，因此属于 answer-blind 评测

得 1 分：间接问题对应的 context 中明确包含目标事实，或者包含无歧义的同义表达

作用：只检验面对间接问题时，被测记忆方法是否把关键事实送入回答模型的上下文，不评价最终回答

3. Application（间接应用）

完整名称为 Indirect Application

判定输入：

`user_message + context + query + explanation + answer`

得 1 分需要同时满足：

- context 中包含目标个人事实
 - answer 根据知识桥梁正确应用该事实，给出相应的提醒、警告、限制、建议或个性化回答
- 作用：检验“记忆检索+知识关联+最终回答”的完整链路是否成功

$\Delta\text{Recall-Naive} = \text{Target Recall} - \text{Naive Recall}$

表示从直接询问变为间接问题后，目标记忆召回下降了多少。越负说明隐式关联检索的损失越大

$\Delta\text{App.-Recall} = \text{Application} - \text{Target Recall}$

表示最终应用分数与目标记忆召回分数之间的差距，用来观察记忆进入上下文后是否被正确应用

$\Delta\text{App.-Naive} = \text{Application} - \text{Naive Recall}$

表示直接召回能力与最终间接应用能力之间的整体差距。越负说明“能记住”与“能在需要时使用”之间的差距越大