

WebArbiter

论文: [WebArbiter: A Principle-Guided Reasoning Process Reward Model for Web Agents](#)

作者: Yao Zhang、Shijie Tang、Zeyu Li

机构: LMU Munich、Technical University of Munich、Munich Center for Machine Learning (MCML)

代码: [YaoZ720/WebArbiterCode](#)

数据: [WebPRMBench](#); [WebArbiter训练数据](#); [WebArbiter模型](#)

Motivation (研究背景)

网页智能体完成任务通常要连续操作很多步，中间一步出错就可能影响后续操作，有些错误还无法撤回。只在最后判断任务成功或失败，无法指出具体哪一步有问题，因此需要在每一步及时评价动作是否正确

Gap (现有研究的不足)

1. Outcome Reward Model只在任务结束时给出结果，无法判断具体哪一步出现问题
 2. 通用LLM-as-Judge成本较高、搜索速度较慢，还可能偏好语言合理但实际无效的动作
 3. 标量WebPRM只输出粗粒度分数，缺少清晰的判断依据
 4. Web-Shepherd依赖预先生成的Checklist，面对网页变化或多条有效路径时，可能低估或错排有效动作
 5. 已有WebPRM基准覆盖的网页环境有限，缺少全面的跨环境评测
-

Problem (本文要解决的问题)

如何构建一个可解释、能够跨网页环境泛化的过程奖励模型，使其结合用户目标、当前网页状态、历史轨迹和候选动作，判断哪个动作更有利于任务完成，并用该判断指导推理时的候选动作选择？

Core idea (文章的核心思想、Insight)

不再使用固定Checklist或单一标量评分，而是让奖励模型根据当前任务和网页状态动态归纳评价原则，再依据这些原则比较候选动作，生成结构化解释并给出最终偏好判断

How（文章核心方法如何设计）

1.构建成对偏好训练数据

作者使用已有的 **WebPRM Collection**。每条原始数据对应网页轨迹中的一个步骤，包含：

- 用户任务
- 当前网页的AXTree文本
- 当前步骤之前的动作和推理
- 专家轨迹中的正确动作 `chosen`
- 被拒绝轨迹中的错误动作 `rejected`

例如，真实数据中的任务是查找公牛队下周末的对手及交手记录：

当前页面：Chicago Bulls比赛列表

历史动作：

```
scroll(0, 500)
click('2667')
```

正确动作`chosen`：

```
click('4383')    # 点击“All Dates”，筛选下周末的比赛
```

错误动作`rejected`：

```
click('2667')
click('4419')    # 直接进入勇士队与公牛队的比赛页面
```

将正确动作分别与错误动作配对：

```
(click('4383'), click('2667'))
(click('4383'), click('4419'))
```

每个动作同时保留策略模型生成该动作时的推理文本。最终，每条训练数据包含：
(任务, 当前网页, 历史轨迹, 候选动作1, 候选动作2, 偏好标签)

本质：把原数据中的一个正确动作和多个错误动作，拆成若干道动作二选一题

2.Stage 1：Reasoning Distillation（推理蒸馏）

先让教师模型o3为9,642条偏好数据生成高质量的判断过程

原始偏好数据为：

(x,y)

其中：

- (x): 任务、当前网页、历史轨迹、候选动作1和候选动作2
- (y): 正确的偏好标签

o3根据 ((x,y)) 生成结构化判断:

$\hat{j} = (\text{State}, \text{Criteria}, \text{Analysis}, \text{Answer})$

- **State**: 总结当前网页状态
- **Criteria**: 根据任务动态提出评价原则
- **Analysis**: 按照这些原则比较两个候选动作
- **Answer**: 给出与偏好标签 (y) 一致的最终选择

例如, 真实数据中:

任务: 找到Wrigleyville影院的Direction & Parking信息

Response 1: click('379'), 进入酒吧相关页面

Response 2: click('364'), 进入Wrigleyville影院主页

偏好标签: Response 2

o3生成:

State: 当前页面包含影院主页和酒吧页面两个链接

Criteria: 目标一致性、推理合理性、元素引用准确性

Analysis: 影院主页更可能包含停车信息

Answer: Response 2

随后将原来的偏好数据转换为SFT数据:

$(x, y) \xrightarrow{o3} (x, \hat{j})$

采用LoRA SFT, 通过标准下一词预测, 让WebArbiter模仿o3生成的 State-Criteria-Analysis-Answer 结构化判断

作用: 先教会WebArbiter如何理解网页、归纳评价原则、比较动作并给出判断, 为下一阶段的强化学习提供初始模型

3. Stage 2: Reinforcement Learning with Verifiable Rewards

使用剩余18,921条偏好数据继续进行强化学习

第二阶段以第一阶段得到的WebArbiter作为初始模型。对于每条数据:

1. 输入任务、当前网页、历史轨迹和两个候选动作;
2. WebArbiter自行生成 State、Criteria、Analysis、Answer ;

3. 将最终 Answer 与真实偏好标签 (y) 比较：

$$R(x, \hat{y}) = \begin{cases} +1, & \hat{y} = y \\ -1, & \hat{y} \neq y \end{cases}$$

其中：

- $\hat{y}$ ：模型预测的偏好
- y ：数据中的真实偏好标签
- 选择正确奖励+1，选择错误奖励-1

作者使用GRPO根据奖励更新模型：

奖励只检查最终 Answer 是否正确，不会分别验证中间的 State、Criteria 和 Analysis

作用：利用真实偏好标签纠正o3可能带来的偏差，提高WebArbiter选择正确动作的准确性和泛化能力

4. 构建WebPRMBench

WebPRMBench包含1,150个网页状态，每个状态包含：

- 1个经过环境验证的正确动作
 - 4个经过筛选和人工检查的错误动作
 - 因此总共形成4,600组成对比较样本
- 数据分布：

环境	状态数量	主要测试内容
Mind2Web Cross-Task	142	跨任务泛化
Mind2Web Cross-Website	148	跨网站泛化
Mind2Web Cross-Domain	417	跨领域泛化
WebArena	201	受控但真实的购物、论坛、CMS、GitLab任务
AssistantBench	30	真实网站上的开放式任务
WorkArena	212	ServiceNow企业办公任务
总计	1,150	4类网页环境

正动作来自AgentRewardBench中的成功轨迹

保留最短有效轨迹中的动作，并由标注者检查轨迹是否单调推动任务进展

负动作由多个开源和闭源策略模型生成，再通过规则过滤和人工检查排除仍然可能成功的动作

评价指标

Pairwise Accuracy

将正确动作分别与每个错误动作比较，统计模型选中正确动作的比例。

Best-of-N Accuracy

一个状态中，只有正确动作同时击败全部4个错误动作，该状态才算判断正确
BoN Accuracy比Pairwise Accuracy更严格，也更接近真实场景下从多个候选动作中选择最佳动作的过程

Experiment

1.验证WebArbiter的提升究竟来自Principles、Reasoning Distillation，还是RL？

Table 3: Ablation results on WEBPRMBENCH with Qwen2.5-7B-Instruct as backbone. We report *Pairwise* and *BoN Acc* across web environments. WebArbiter, combining principle-guided reasoning distillation with RL, achieves the highest overall performance.

Method	Mind2Web		WebArena		AssistantBench		WorkArena		Avg.	
	Pairwise	BoN	Pairwise	BoN	Pairwise	BoN	Pairwise	BoN	Pairwise	BoN
Instruct (Original)	77.79	39.18	74.88	42.79	84.17	53.33	77.58	35.85	77.61	42.78
Instruct + Cold Start RL	96.18	86.00	71.10	35.80	72.40	33.60	74.90	37.90	78.15	48.33
Instruct + Cold Start RL + Principles	96.18	88.00	77.80	46.30	80.10	48.90	82.40	51.80	84.12	58.75
Instruct + SFT _{w/o Principles} + RL	98.48	94.34	74.60	41.50	77.20	40.20	79.10	44.60	82.35	55.16
★ WebArbiter-7B	97.07	89.53	88.43	68.66	89.17	70.00	82.09	70.19	89.19	74.60

基座模型 Qwen2.5-7B-Instruct

Method	Stage 1	Stage 2
Instruct	无	无
Cold Start RL	跳过	直接RL
Cold Start RL + Principles	跳过	使用Principles提示进行RL
SFT _{w/o Principles} + RL	蒸馏不含Principles的普通推理	RL
WebArbiter	蒸馏包含Principles的结构化推理	RL

2.没有预先给出正确动作，WebArbiter自行选择候选动作并真正执行，最后根据整个任务是否成功评分

Table 5: Success Rates (%) of trajectory search with GPT-4o-mini and GPT-4o as policy on WebArena-Lite. * Results reported from the WebShepherd (Chae et al., 2025). Δ is relative to the *w/o Trajectory Search* baseline. Our WebArbiter consistently achieves the highest gains across both policy models.

Policy	WebPRM	Shopping	CMS	Reddit	GitLab	MAP	Avg.	Δ
GPT-4o-mini	w/o Trajectory Search*	21.74	22.86	19.05	34.38	19.35	23.48	–
	GPT-4o-mini	24.44	22.86	26.32	33.33	15.38	24.47	+0.99
	WebShepherd-8B*	26.09	45.71	23.81	40.62	35.48	34.34	+10.86
	★ WebArbiter-7B	37.78	42.86	36.84	46.67	38.46	40.52	+17.04
GPT-4o	w/o Trajectory Search*	23.91	31.43	28.57	56.25	19.35	31.90	–
	GPT-4o-mini	26.67	37.14	42.11	40.00	19.23	33.03	+1.13
	WebShepherd-8B*	30.43	42.86	47.62	46.88	35.48	40.65	+8.75
	★ WebArbiter-7B	44.44	42.86	52.63	56.67	38.46	47.01	+15.11

3.比较只学习最终答案的SFT、学习完整推理过程的Reasoning Distillation，以及在推理蒸馏后使用RL的效果

Table 4: Results on WEBPRMBENCH under full-data and limited-data (10K) training regimes. We report *Pairwise* and *BoN Acc* across web environments. Reasoning distillation improves over answer-only SFT, while WebArbiter, i.e., reasoning distillation + RL, achieves the best overall performance.

Method	Mind2Web		WebArena		AssistantBench		WorkArena		Avg.	
	<i>Pairwise</i>	<i>BoN</i>	<i>Pairwise</i>	<i>BoN</i>	<i>Pairwise</i>	<i>BoN</i>	<i>Pairwise</i>	<i>BoN</i>	<i>Pairwise</i>	<i>BoN</i>
<i>Train on Full Data</i>										
Instruct + SFT	85.14	60.91	80.85	52.73	82.50	56.67	79.57	52.88	82.02	55.80
Instruct + Distilled + SFT	87.42	61.18	81.59	52.73	83.33	63.33	81.13	56.73	83.37	58.49
★ WebArbiter-7B (Instruct + Distilled + RL)	97.07	89.53	88.43	68.66	89.17	70.00	82.09	70.19	89.19	74.60
<i>Train on 10K (Stage-1 Reasoning Distillation) Data</i>										
Instruct + SFT	84.53	60.82	82.21	58.71	82.50	56.67	80.58	39.62	82.46	53.96
Instruct + Distilled	85.20	63.40	83.10	61.80	83.00	60.20	81.40	55.60	83.18	60.25

对比方法：

- **Instruct + SFT**：只学习最终偏好答案，不学习中间推理
- **Instruct + Distilled + SFT**：先学习o3生成的结构化推理，再进行Answer-only SFT
- **WebArbiter**：先进行Reasoning Distillation，再使用RL优化最终判断